



Proyecto Final

Control de Retrasos y Cancelaciones en Olist

Sustentante

Ángel Esteban Félix Ferreras

Maestría

Ciencia de Datos

Profesor

Jorge Valtuena

Asignatura

Visualización de Datos

Santo Domingo, República Dominicana

6 de mayo de 2026

Tabla de contenidos

1	Introducción	3
2	Descripción del dataset	4
2.1	Fuentes originales	4
2.2	Tabla procesada: orders_processed.xlsx	5
3	Objetivo del análisis y público objetivo	9
4	Diseño del dashboard	10
5	Principales hallazgos	11
5.1	Costo de cancelaciones y el efecto de los retrasos	11
5.2	Tendencia al aumento del costo de cancelación	12
5.3	Problemas de capacidad operativa	13
5.4	El 37 % del costo de retraso está entre los estados São Paulo y Río de Janeiro . . .	14
5.5	Salud, belleza y herramientas de construcción presentan más cancelaciones que el resto de productos	17
6	Conclusión	19

1. Introducción

Este documento complementa el dashboard interactivo desarrollado en Looker Studio para analizar el efecto de las cancelaciones en los pedidos de Olist. A partir del dataset público **Brazilian E-Commerce Public Dataset** (disponible en [Kaggle](#)), se construyó una tabla única enriquecida que consolida información de clientes, vendedores, productos, pagos, reseñas y geolocalización, permitiendo responder preguntas clave sobre puntualidad de entregas, causas de retrasos y su impacto financiero.

Para mí, este proyecto ha representado una gratificante aventura: venir del ecosistema R y enfrentarme por primera vez a un proceso de transformación de datos tan avanzado con pandas. Fue necesario integrar nueve archivos CSV originales, calcular indicadores logísticos (días de retraso, tiempos de manipulación y tránsito, margen, coste de cancelación, etc.) y exportar un archivo `orders_processed.xlsx` que, cargado como Google Sheet, alimenta el dashboard. Todo el pipeline de preparación se desarrolló con un enfoque reproducible mediante Docker y Nix, y el código completo está disponible en el repositorio [olist-logistics-dashboard](#).

El presente informe recorre cada etapa del trabajo: descripción del dataset y la tabla procesada, objetivos del análisis, decisiones de diseño del dashboard y principales hallazgos obtenidos. Al final, se demuestra cómo el tablero construido proporciona una herramienta narrativa, accionable y orientada a un público no técnico.

2. Descripción del dataset

2.1. Fuentes originales

Los datos provienen de las siguientes tablas (archivos CSV en la carpeta raw-data/):

- **olist_orders_dataset.csv** – pedidos (estado, fechas, estimación de entrega)
- **olist_order_items_dataset.csv** – productos incluidos en cada pedido (precio, flete, límite de envío)
- **olist_products_dataset.csv** – catálogo de productos (categoría, dimensiones, peso)
- **olist_order_reviews_dataset.csv** – reseñas (puntuación, fechas de creación y respuesta)
- **olist_order_payments_dataset.csv** – pagos (tipo, cuotas, valor)
- **olist_customers_dataset.csv** – clientes (ciudad, estado)
- **olist_sellers_dataset.csv** – vendedores (ciudad, estado)
- **olist_geolocation_dataset.csv** – coordenadas geográficas por código postal

En la siguiente imagen se presenta el esquema de la base de datos normalizada de Olist.




Figura 1. Esquema de la base de datos normalizada de Olist. Fuente: Kaggle Brazilian E-Commerce (Olist).

2.2. Tabla procesada: orders_processed.xlsx

Aunque los datos normalizados son excelentes para la operación diaria del negocio, para extraer conclusiones estratégicas es necesario realizar un proceso de agregación que permita responder las preguntas de negocio planteadas.

Con este fin se creó el script `prepare_dashboard_data.py`, mediante el cual se generó una sola tabla desnormalizada con **99 420 filas** (una por pedido) y **38 columnas** que enriquecen la información de órdenes con los datos de productos, clientes y vendedores.

A continuación se describen todas las variables, indicando su origen o fórmula de cálculo:

Variable	Descripción
order_id	Identificador único del pedido (proviene de olist_orders_dataset)
order_status	Estado del pedido (delivered, shipped, canceled, etc.)
order_purchase_timestamp	Fecha/hora de la compra
order_approved_at	Fecha/hora de aprobación del pedido
order_delivered_carrier_date	Fecha en que el transportista recoge el pedido del vendedor
order_delivered_customer_date	Fecha de entrega real al cliente
order_estimated_delivery_date	Fecha prometida de entrega
review_score	Puntuación de la reseña (1 a 5)
review_creation_date	Fecha en que se creó la reseña
review_answer_timestamp	Fecha en que el cliente respondió la reseña
order_main_category	Categoría principal del pedido (agrupada en 13 categorías en inglés)
order_main_seller	ID del vendedor que aportó el producto de mayor valor en el pedido
order_last_shipping_date	Última fecha límite de envío entre los ítems del pedido
order_volume_cm3	Volumen total del pedido (suma de productos)
order_weight_g	Peso total del pedido (suma de productos)

Variable	Descripción
<code>order_price</code>	Suma de los precios de los productos
<code>order_freight</code>	Suma de los costos de flete
<code>customer_unique_id</code>	Identificador único del cliente
<code>customer_city</code>	Ciudad del cliente
<code>customer_state</code>	Estado del cliente
<code>customer_lat</code>	Latitud promedio de la ciudad del cliente
<code>customer_lng</code>	Longitud promedio de la ciudad del cliente
<code>seller_id</code>	ID del vendedor (se une con <code>order_main_seller</code>)
<code>seller_city</code>	Ciudad del vendedor
<code>seller_state</code>	Estado del vendedor
<code>seller_lat</code>	Latitud promedio de la ciudad del vendedor
<code>seller_lng</code>	Longitud promedio de la ciudad del vendedor
<code>is_delivered</code>	Indicador booleano: True si el pedido fue entregado (estado <code>delivered</code> o fecha de entrega no nula)
<code>delay_days</code>	Días de retraso (fecha real – fecha estimada, truncado a ≥ 0 , solo para entregados)
<code>is_on_time</code>	True si <code>delay_days == 0</code> y <code>is_delivered</code>
<code>is_delayed</code>	True si <code>delay_days > 0</code>
<code>is_pending</code>	True si no ha sido entregado y no tiene reseña (pedido pendiente)

Variable	Descripción
<code>is_canceled</code>	True si el pedido fue marcado como cancelado o si no fue entregado pero cuenta con una review del cliente.
<code>active_delay_days</code>	Días que un pedido pendiente ya superó la fecha prometida (calculado hasta la fecha máxima de compra)
<code>total_margin</code>	Margen estimado (15 % del precio total del pedido)
<code>cancellation_cost</code>	Coste de cancelación: margen + flete si ya fue recogido por el transportista; solo margen si no fue recogido pero tiene reseña; 0 en otros casos
<code>seller_handling_days</code>	Días entre la aprobación y la entrega al transportista (solo cuando ambas fechas existen)
<code>transit_days</code>	Días entre la recogida del transportista y la entrega al cliente (solo cuando ambas fechas existen)

3. Objetivo del análisis y público objetivo

Objetivo. Proporcionar al equipo de operaciones logísticas una herramienta visual que permita:

- Monitorear mes a mes el impacto financiero de los retrasos.
- Identificar las categorías de producto y regiones con mayor incidencia de retrasos.
- Monitorear cómo las acciones tomadas reducen los tiempos de espera para los clientes.

Público objetivo. Responsables de logística, gerentes de marketplace y analistas de negocio sin perfil técnico. Por ello, el dashboard prioriza la claridad visual, la interactividad intuitiva (filtros, tablas) y una narrativa que guía desde lo general hasta lo particular.

4. Diseño del dashboard



Figura 2. Vista general del dashboard en Looker Studio. Fuente: elaboración propia.

El dashboard se implementó en Looker Studio siguiendo una estructura narrativa de 3 secciones:

1. **Visión macro** – Tarjetas con totales importantes que conviene vigilar de manera continua.
2. **Análisis temporal** – Progreso mes a mes del margen perdido y los días de retraso presentados por Olist en los pedidos retrasados frente a los entregados a tiempo.
3. **Causas raíz** – Barras de categorías más retrasadas y heatmap que muestra las rutas de vendedor a cliente para identificar focos de problemas.

5. Principales hallazgos

En esta sección nos ponemos en los zapatos del encargado de logística para identificar cómo este dashboard le ayudaría a mejorar su gestión y proveer un mejor servicio a los clientes.

5.1. Costo de cancelaciones y el efecto de los retrasos



Figura 3. Tarjetas de resumen: costo total de cancelaciones, proporción de pedidos retrasados y satisfacción en pedidos retrasados. Fuente: elaboración propia.

Con la primera sección nuestro encargado ya sabe que desde enero de 2017 la empresa ha perdido **BRL 53k** por concepto de cancelaciones, de los cuales **BRL 50k** (el 96 %) están relacionados con entregas tardías, a pesar de que las entregas tardías solo representan el 9 % de los pedidos vendidos. Además, recibir entregas tardías baja la satisfacción promedio de los clientes a 2 de 5 estrellas, por lo que es un tema crítico que cuesta dinero y reputación a la empresa.

5.2. Tendencia al aumento del costo de cancelación



Figura 4. Evolución mensual del costo de cancelaciones por retraso. Fuente: elaboración propia.

Con esta gráfica se obtiene evidencia indiscutible de que los retrasos son los que derivan en cancelaciones de pedidos mes a mes. También sirve para ver si las acciones que realiza nuestro encargado en logística están logrando un efecto positivo en la reducción de este costo.

En la gráfica podemos ver que los valores de costo de cancelación fluctúan de mes a mes y presentan una tendencia al alza. Aunque agosto de 2018 tuvo menos costos que julio de 2018, ese buen progreso todavía no es suficiente para cambiar la tendencia que se observa desde enero de 2017.

5.3. Problemas de capacidad operativa



Figura 5. Días promedio de entrega para pedidos entregados a tiempo vs. pedidos retrasados.

Fuente: elaboración propia.

Gracias a `order_delivered_carrier_date` podemos dividir cuánto tiempo se tomaron los vendedores en preparar la orden y, por tanto, saber cuántos días estuvo el producto en manos de Olist antes de ser recibido. Una meta operativa deseable es que el tiempo promedio de las órdenes retrasadas y el de las órdenes entregadas a tiempo sean iguales; de esa manera, podemos afirmar que el retraso provino del vendedor y no de la empresa.

Mediante esta gráfica el encargado puede controlar cómo sus acciones están influyendo sobre el tiempo promedio de las órdenes retrasadas, para que en el futuro las órdenes que se entreguen tarde

siempre se deban a la parte del vendedor y no a una falta de gestión de Olist.

Sin duda, el progreso mostrado en julio y agosto de 2018 fue sorprendente, y será importante ver si esa buena racha se mantiene o si fue solo un efecto puntual y no un cambio sostenible.

5.4. El 37 % del costo de retraso está entre los estados São Paulo y Río de Janeiro

Cancelaciones por estado - Vendedor vs Cliente				
customer_state / cancelation_cost				
seller_state	SP	RJ	MG	
SP	R\$ 13.165	R\$ 5.380	R\$ 2.917	
MG	R\$ 1.372	R\$ 1.226	R\$ 1.061	
PR	R\$ 1.237	R\$ 408	R\$ 241	
RJ	R\$ 1.204	R\$ 668	R\$ 159	
SC	R\$ 628	R\$ 239	R\$ 93	
BA	R\$ 148	R\$ 117	R\$ 64	
RS	R\$ 195	R\$ 131	R\$ 55	
DF	R\$ 143	R\$ 217	R\$ 0	
GO	R\$ 68	R\$ 36	R\$ 37	

Figura 6. Distribución geográfica del costo de cancelación por retrasos, según estado del vendedor y del cliente. Fuente: elaboración propia.

En la gráfica se puede ver que **BRL 13k** y **BRL 5k** de los **BRL 50k** (37 %) perdidos debido a cancelaciones por retrasos se concentran en los viajes que van de São Paulo (SP) a São Paulo (SP) y de São Paulo (SP) a Río de Janeiro (RJ). Vale la pena observar cómo estas rutas han progresado a lo largo del tiempo en cuanto a costo, para estar atentos a mejorar la gestión en ambas.



Figura 7. Dashboard filtrado para la ruta São Paulo → São Paulo. Fuente: elaboración propia.

Al seleccionar los **viajes de São Paulo a São Paulo** podemos ver que su proporción de cancelaciones (6 %) es menor que el 9 % del promedio general y que la línea de tendencia muestra solo un incremento moderado. En mayo de 2018 se produjo un pico de costo que al parecer ya ha sido solucionado al observar los meses siguientes, por lo que podemos decir que la gestión para estos viajes ha mejorado con el tiempo y las cancelaciones están bajando en impacto.



Figura 8. Dashboard filtrado para la ruta São Paulo → Río de Janeiro. Fuente: elaboración propia.

En el caso de los **viajes de São Paulo a Río de Janeiro** vemos que el costo de esta ruta es muy elevado, ya que el 17 % de los pedidos terminan en retrasos. Además, desde noviembre de 2017 hasta junio de 2018 se presentaron incrementos significativos en el costo de cancelaciones por retrasos. Sin duda, las acciones tomadas para julio y agosto de 2018 tuvieron un efecto significativo en la reducción del costo.

5.5. Salud, belleza y herramientas de construcción presentan más cancelaciones que el resto de productos




Figura 9. Costo de cancelación por retrasos según la categoría principal del producto. Fuente: elaboración propia.

Si todos los productos tuvieran el mismo impacto proporcional sobre el valor de cancelaciones por retrasos, esta gráfica sería una pared uniforme. Sin embargo, existe una clara correlación entre el tipo de producto y la capacidad que tiene la empresa de entregarlos a tiempo. Esto puede deberse a diversos factores: los proveedores que venden estos productos, que sean más caros y por eso impacten más, que sean más comprados, o simplemente que sean más grandes o pesados y signifiquen un reto logístico que es necesario abordar. Sin importar cuál sea la causa, es un tema que se debe explorar y corregir.



Figura 10. Dashboard filtrado para la categoría de productos de salud. Fuente: elaboración propia.

Al centrar el dashboard solo en los productos de salud, podemos ver que estos se encuentran entre los que marcan el 9 % de pedidos cancelados y que, efectivamente, los costos de cancelaciones se han incrementado durante 2018 especialmente. También podemos ver que **BRL 2.3k** de los **BRL 4.5k** cancelados por retrasos se concentran en las siguientes rutas:

- São Paulo a São Paulo
- Minas Gerais a Minas Gerais
- São Paulo a Minas Gerais
- São Paulo a Río de Janeiro
- Minas Gerais a São Paulo

6. Conclusión

El dashboard desarrollado cuenta una historia clara y estructurada: comienza exponiendo el problema central —pérdidas por cancelaciones y baja satisfacción—, continúa con la evolución temporal que confirma a los retrasos como causa principal, y desciende hasta las causas raíz geográficas y por tipo de producto. Esta narrativa visual, construida con tarjetas de alto impacto, series temporales, gráficos de barras y mapas de calor, permite que cualquier responsable de logística, incluso sin formación técnica, pueda seguir el hilo conductor y obtener respuestas inmediatas.

Los hallazgos obtenidos son directamente accionables. Se identificó que el 96 % del costo de cancelaciones está vinculado a entregas tardías; que las rutas São Paulo–São Paulo y São Paulo–Río de Janeiro concentran el 37 % de esas pérdidas; y que categorías como salud, belleza y herramientas de construcción presentan un comportamiento atípicamente elevado. Al filtrar el dashboard por estas categorías o rutas, el encargado puede localizar exactamente los focos de pérdida y priorizar sus intervenciones. Por ejemplo, en productos de salud, cinco corredores logísticos acumulan más de la mitad del costo cancelado, lo que facilita una investigación focalizada.

Finalmente, el diseño del dashboard garantiza que los resultados puedan ser monitoreados a lo largo del tiempo. La combinación de filtros globales, líneas de tendencia y comparativas mes a mes convierte al tablero en una herramienta viva, donde el impacto de las medidas correctivas puede evaluarse.